

Modelos Estadísticos

Maestría en Computo Estadístico

Dr. Marco Antonio Aquino López

Centro de Investigación en Matemáticas

2026



¿Dónde estamos en la historia?

Hasta ahora hemos visto tres escenarios:

- 1 **Modelos conjugados**: la posterior puede obtenerse en forma cerrada.
- 2 **Regresión bayesiana conjugada**: seguimos teniendo expresiones analíticas útiles.
- 3 **EM**: cuando la inferencia directa es difícil, podemos buscar una solución iterativa.

Pero ahora surge una pregunta natural:

Pregunta central

¿Qué hacemos cuando queremos inferencia bayesiana completa, pero no hay conjugación y EM no es suficiente?

Cuando la conjugación funciona

En los modelos conjugados podemos calcular exactamente

$$p(\theta \mid y).$$

Esto nos permite obtener directamente:

- medias posteriores,
- varianzas posteriores,
- intervalos creíbles,
- predicciones.

Ejemplos típicos:

- Beta–Binomial,
- Gamma–Poisson,
- Normal–Normal.

La ventaja es clara: **toda la incertidumbre se obtiene de forma explícita.**

Cuando la conjugación falla

En muchos problemas reales, la posterior

$$p(\theta | y)$$

ya no tiene una forma conocida ni fácil de manipular.

Entonces aparecen dificultades como:

- integrales imposibles de resolver,
- distribuciones posteriores no estándar,
- múltiples parámetros interactuando de manera compleja,
- variables latentes o estructuras jerárquicas.

En esos casos, las fórmulas cerradas desaparecen.

¿Qué nos dio EM?

El algoritmo EM fue una respuesta muy útil cuando la inferencia directa se complica. EM nos permite encontrar una estimación puntual:

$$\hat{\theta}_{EM}.$$

Eso es muy valioso cuando:

- hay datos incompletos,
- hay variables latentes,
- maximizar la verosimilitud directamente es difícil.

Pero tiene una limitación fundamental:

Limitación

EM produce una estimación, no una distribución posterior.

El problema real

En inferencia bayesiana no queremos sólo un valor “bueno” de θ . Queremos responder preguntas como:

- ¿qué valores de θ son plausibles?
- ¿qué tan inciertos son nuestros parámetros?
- ¿qué tan concentrada o dispersa es la posterior?
- ¿hay varias regiones plausibles en el espacio paramétrico?

En otras palabras, queremos conocer

$$p(\theta \mid y),$$

no solamente un estimador puntual.

Ejemplo guía: una mezcla de dos poblaciones

Supongamos que observamos datos

$$y_1, y_2, \dots, y_n,$$

y creemos que provienen de **dos grupos distintos**, pero no sabemos a cuál grupo pertenece cada observación.

Por ejemplo:

- dos subpoblaciones biológicas,
- dos procesos de generación distintos,
- dos tipos de eventos dentro de una misma muestra.

La dificultad central es que la pertenencia al grupo es **desconocida**.

Modelo de mezcla

Un modelo sencillo es

$$y_i \sim \pi \mathcal{N}(\mu_1, \sigma^2) + (1 - \pi) \mathcal{N}(\mu_2, \sigma^2),$$

donde:

- μ_1 y μ_2 son las medias de los dos grupos,
- π es la proporción del primer grupo,
- σ^2 se asume conocida para simplificar la exposición.

Entonces los parámetros de interés son

$$\theta = (\mu_1, \mu_2, \pi).$$

Y además hay una estructura latente: no sabemos qué observaciones pertenecen a cada componente.

Lo que EM sí puede hacer aquí

Este es un problema clásico donde EM funciona bien para encontrar una solución puntual. EM puede producir estimaciones como

$$\hat{\mu}_1, \quad \hat{\mu}_2, \quad \hat{\pi}.$$

Además, EM es muy natural en este contexto porque:

- hay asignaciones latentes de grupo,
- la estructura “faltante” puede tratarse en el paso E,
- luego se actualizan parámetros en el paso M.

Pero sigue pendiente la pregunta bayesiana.

La pregunta que EM no responde

Supongamos que EM encuentra un ajuste razonable.

Aun así, queremos saber:

- ¿qué tanta incertidumbre hay en μ_1 y μ_2 ?
- ¿qué tan bien separadas están realmente las dos poblaciones?
- ¿qué pasa si los grupos se traslapan mucho?
- ¿hay varias configuraciones plausibles de parámetros?

EM no responde eso, porque sólo produce un punto.

Lo que realmente queremos

$$p(\mu_1, \mu_2, \pi \mid y).$$

La formulación bayesiana

Para proceder de manera bayesiana, especificamos priors. Por ejemplo:

$$\mu_1 \sim \mathcal{N}(0, 100), \quad \mu_2 \sim \mathcal{N}(0, 100),$$

$$\pi \sim \text{Beta}(1, 1).$$

Entonces nuestra meta es estudiar

$$p(\mu_1, \mu_2, \pi \mid y) \propto p(y \mid \mu_1, \mu_2, \pi) p(\mu_1) p(\mu_2) p(\pi).$$

El problema es que esta posterior ya no tiene una forma simple.

El obstáculo matemático

Recordemos la regla de Bayes:

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)}.$$

Y la constante de normalización es

$$p(y) = \int p(y | \theta)p(\theta) d\theta.$$

En modelos sencillos, esta integral puede resolverse.

En nuestro problema de mezcla, en general no.

Además, la posterior puede ser:

- asimétrica,
- multimodal,
- difícil de integrar,
- difícil de muestrear directamente.

Entonces, ¿qué hacemos?

Llegamos a una situación nueva:

- la inferencia bayesiana completa es deseable,
- no tenemos conjugación,
- no podemos integrar explícitamente,
- EM no es suficiente porque sólo da una estimación puntual.

Entonces necesitamos una idea distinta.

Cambio de perspectiva

En lugar de buscar una fórmula cerrada para la posterior, intentaremos **simular** de ella.

La idea fundamental

Supongamos que pudiéramos generar muestras

$$\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$$

de la distribución posterior

$$p(\theta \mid y).$$

Entonces podríamos aproximar cualquier cantidad de interés.

Por ejemplo, la media posterior:

$$E[\theta \mid y] \approx \frac{1}{N} \sum_{t=1}^N \theta^{(t)}.$$

Y también:

- varianzas,
- cuantiles,
- intervalos creíbles,

La inferencia se vuelve simulación

Esta es la gran idea conceptual:

Idea central

Si no podemos resolver la posterior analíticamente, quizá podamos aproximarla mediante muestras.

Eso transforma el problema de inferencia en un problema de simulación.

Pero aparece una nueva dificultad:

Nueva dificultad

¿Cómo generamos muestras de una distribución complicada, posiblemente no normalizada, y de alta dimensión?

Aquí aparece MCMC

La respuesta es:

Markov Chain Monte Carlo

MCMC es una familia de métodos para generar muestras aproximadas de una distribución complicada.

La idea es construir una sucesión

$$\theta^{(1)}, \theta^{(2)}, \theta^{(3)}, \dots$$

de tal forma que, después de suficientes iteraciones, estos valores se comporten como muestras de

$$p(\theta \mid y).$$

¿Por qué “Markov Chain”?

Porque la secuencia se construye como una **cadena de Markov**:

$$\theta^{(t+1)} \text{ depende de } \theta^{(t)},$$

pero no directamente de toda la historia previa.

Es decir, cada nuevo valor se genera a partir del valor actual.

La clave está en diseñar esa cadena de manera que su distribución de equilibrio sea precisamente la posterior que queremos estudiar.

¿Por qué “Monte Carlo”?

Porque al final usaremos las muestras simuladas para aproximar cantidades de interés. Eso es exactamente la idea de Monte Carlo:

- simular valores aleatorios,
- promediar funciones de esos valores,
- aproximar integrales complicadas.

Así, MCMC combina dos ideas:

- 1 construir una cadena de Markov,
- 2 usar simulación Monte Carlo sobre esa cadena.

¿Qué necesitamos realmente conocer?

Una observación muy importante es que, en muchos algoritmos MCMC, no necesitamos conocer la posterior completa con su constante de normalización.

Basta con conocer una función proporcional a ella:

$$p(\theta | y) \propto p(y | \theta)p(\theta).$$

Esto es fundamental, porque precisamente la normalización suele ser la parte imposible de calcular.

Primer algoritmo: Metropolis–Hastings

El algoritmo de Metropolis–Hastings construye una cadena siguiendo una lógica muy simple:

- 1 Partimos de un valor actual $\theta^{(t)}$.
- 2 Proponemos un nuevo valor θ^* .
- 3 Decidimos si aceptarlo o rechazarlo.

De esta forma, la cadena explora las regiones de mayor probabilidad de la posterior.

Paso 1: proponer

Dado el valor actual $\theta^{(t)}$, generamos una propuesta

$$\theta^* \sim q(\theta^* \mid \theta^{(t)}),$$

donde q es una distribución de propuesta.

Por ejemplo, una elección común es una caminata aleatoria:

$$\theta^* = \theta^{(t)} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \tau^2).$$

Esto quiere decir que proponemos movernos “cerca” del valor actual.

Paso 2: comparar propuesta con estado actual

Luego comparamos qué tan plausible es la propuesta frente al valor actual.
En el caso simétrico más simple, usamos

$$\alpha = \min \left(1, \frac{p(y | \theta^*)p(\theta^*)}{p(y | \theta^{(t)})p(\theta^{(t)})} \right).$$

Interpretación:

- si la propuesta mejora mucho, casi siempre la aceptamos;
- si empeora, todavía puede aceptarse, pero con menor probabilidad.

Paso 3: aceptar o rechazar

Finalmente:

- con probabilidad α , aceptamos la propuesta y ponemos

$$\theta^{(t+1)} = \theta^*;$$

- con probabilidad $1 - \alpha$, rechazamos la propuesta y repetimos

$$\theta^{(t+1)} = \theta^{(t)}.$$

Así obtenemos una secuencia dependiente de valores que, bajo condiciones adecuadas, converge a la distribución objetivo.

La intuición detrás del algoritmo

Metropolis–Hastings hace un balance muy útil:

- favorece moverse hacia regiones con mayor probabilidad posterior,
- pero no impide completamente explorar otras regiones,
- evita quedarse atrapado de forma puramente determinista.

Por eso el método no sólo encuentra un máximo, sino que explora toda la distribución.

Conexión conceptual con EM

EM	MCMC
Busca una estimación puntual	Explora una distribución posterior
Esencialmente optimiza	Esencialmente simula
Da un solo valor final	Da una nube de valores plausibles
No cuantifica incertidumbre de manera directa	Cuantifica incertidumbre de forma natural
Puede ser más rápido	Suele ser más costoso computacionalmente

Resumen

EM busca “el mejor valor”. MCMC busca describir “toda la incertidumbre”.

Aplicado a nuestro ejemplo de mezcla

En el modelo de mezcla, MCMC nos permitirá generar muestras de

$$(\mu_1, \mu_2, \pi) \mid y.$$

Con esas muestras podremos:

- estimar medias posteriores,
- construir intervalos creíbles,
- ver dependencia entre parámetros,
- estudiar multimodalidad,
- comparar con la solución puntual de EM.

Aquí es donde MCMC muestra su verdadera ventaja.

La gran diferencia con optimización

Vale la pena enfatizar esta idea:

- Un algoritmo de optimización quiere encontrar un máximo.
- MCMC quiere explorar una distribución.

Por eso, aunque ambos sean iterativos, persiguen objetivos distintos.

Mensaje clave

MCMC no busca un solo “mejor” parámetro, sino una representación de todos los valores plausibles dados los datos.

Algoritmo Metropolis–Hastings

Dado el estado actual $\theta^{(t)}$:

Paso 1. Proponer un nuevo valor

$$\theta^* \sim q(\theta^* \mid \theta^{(t)}),$$

donde q es una distribución de propuesta.

Paso 2. Calcular la probabilidad de aceptación

$$\alpha(\theta^{(t)}, \theta^*) = \min \left(1, \frac{\pi(\theta^*)q(\theta^{(t)} \mid \theta^*)}{\pi(\theta^{(t)})q(\theta^* \mid \theta^{(t)})} \right).$$

Paso 3. Aceptar o rechazar

- con probabilidad α , ponemos $\theta^{(t+1)} = \theta^*$;
- en otro caso, ponemos $\theta^{(t+1)} = \theta^{(t)}$.

Caso importante: propuesta simétrica

Si la propuesta satisface

$$q(\theta^* | \theta) = q(\theta | \theta^*),$$

entonces la razón de aceptación se simplifica a

$$\alpha(\theta, \theta^*) = \min \left(1, \frac{\pi(\theta^*)}{\pi(\theta)} \right).$$

Un ejemplo clásico es la propuesta de caminata aleatoria:

$$\theta^* = \theta^{(t)} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \tau^2).$$

A este caso se le suele llamar:

Random Walk Metropolis

¿Por qué la constante de normalización no importa?

Supongamos que

$$\pi(\theta) = \frac{\tilde{\pi}(\theta)}{C},$$

donde C es una constante desconocida.

Entonces:

$$\frac{\pi(\theta^*)}{\pi(\theta)} = \frac{\tilde{\pi}(\theta^*)/C}{\tilde{\pi}(\theta)/C} = \frac{\tilde{\pi}(\theta^*)}{\tilde{\pi}(\theta)}.$$

La constante se cancela.

Por eso, en Bayes, normalmente basta con conocer:

$$p(y | \theta)p(\theta).$$

Balance detallado

Una condición suficiente muy importante para garantizar estacionariedad es el **balance detallado**:

$$\pi(\theta) P(\theta, \theta^*) = \pi(\theta^*) P(\theta^*, \theta).$$

Interpretación:

- el flujo de probabilidad de θ hacia θ^* es igual
- al flujo de probabilidad de θ^* hacia θ .

Cuando esta igualdad se cumple para todos los pares de estados, π es estacionaria.

Bosquejo: por qué balance detallado implica estacionariedad

Supongamos que se cumple:

$$\pi(\theta) P(\theta, \theta^*) = \pi(\theta^*) P(\theta^*, \theta).$$

Integrando respecto a θ :

$$\int \pi(\theta) P(\theta, \theta^*) d\theta = \int \pi(\theta^*) P(\theta^*, \theta) d\theta.$$

Como $\pi(\theta^*)$ no depende de θ :

$$\int \pi(\theta) P(\theta, \theta^*) d\theta = \pi(\theta^*) \int P(\theta^*, \theta) d\theta.$$

Pero la última integral vale 1, así que:

$$\int \pi(\theta) P(\theta, \theta^*) d\theta = \pi(\theta^*).$$

Eso es exactamente estacionariedad.

Transición en Metropolis–Hastings

Si $\theta^* \neq \theta$, la probabilidad de transición de θ a θ^* es

$$P(\theta, \theta^*) = q(\theta^* | \theta) \alpha(\theta, \theta^*),$$

donde

$$\alpha(\theta, \theta^*) = \min \left(1, \frac{\pi(\theta^*) q(\theta | \theta^*)}{\pi(\theta) q(\theta^* | \theta)} \right).$$

Además, existe una masa de probabilidad en quedarse en el mismo lugar, correspondiente al rechazo.

Bosquejo de prueba para Metropolis–Hastings

Queremos mostrar que

$$\pi(\theta)P(\theta, \theta^*) = \pi(\theta^*)P(\theta^*, \theta).$$

Para $\theta^* \neq \theta$:

$$\pi(\theta)P(\theta, \theta^*) = \pi(\theta) q(\theta^* | \theta) \min \left(1, \frac{\pi(\theta^*)q(\theta | \theta^*)}{\pi(\theta)q(\theta^* | \theta)} \right).$$

Usando la identidad

$$a \min(1, b/a) = \min(a, b),$$

obtenemos:

$$\pi(\theta)P(\theta, \theta^*) = \min \left(\pi(\theta)q(\theta^* | \theta), \pi(\theta^*)q(\theta | \theta^*) \right).$$

Por simetría,

$$\pi(\theta^*)P(\theta^*, \theta) = \min \left(\pi(\theta^*)q(\theta | \theta^*), \pi(\theta)q(\theta^* | \theta) \right).$$

Son iguales. Por tanto, se cumple balance detallado.

Idea conceptual de la prueba

La aceptación en Metropolis–Hastings está diseñada exactamente para corregir el sesgo que introduce la propuesta q .

Si una propuesta favorece ciertos movimientos más que otros, la razón

$$\frac{q(\theta \mid \theta^*)}{q(\theta^* \mid \theta)}$$

compensa esa asimetría.

Al mismo tiempo, la razón

$$\frac{\pi(\theta^*)}{\pi(\theta)}$$

empuja a la cadena hacia regiones más probables de la distribución objetivo.

El resultado final es una cadena cuya distribución estacionaria es π .

¿Qué significa que la cadena “converja”?

Tener una distribución estacionaria no basta por sí solo.

También necesitamos que, empezando desde un valor inicial arbitrario, la distribución de $\theta^{(t)}$ se acerque a π cuando $t \rightarrow \infty$.

Eso requiere ciertas condiciones sobre la cadena, como:

- irreducibilidad,
- aperiocidad,
- recurrencia positiva.

Irreducibilidad y aperiocidad

Irreducibilidad: desde cualquier estado, la cadena puede eventualmente alcanzar cualquier región relevante del espacio.

Aperiocidad: la cadena no queda atrapada en ciclos deterministas.

Estas condiciones evitan comportamientos patológicos y ayudan a garantizar que la cadena realmente explore toda la distribución objetivo.

Teorema ergódico para cadenas de Markov

Bajo condiciones adecuadas, si la cadena es ergódica con distribución estacionaria π , entonces para funciones integrables f :

$$\frac{1}{N} \sum_{t=1}^N f(\theta^{(t)}) \longrightarrow E_{\pi}[f(\theta)] \quad \text{cuando } N \rightarrow \infty.$$

Este resultado es la base teórica de MCMC:

Mensaje clave

Las medias empíricas calculadas a partir de la cadena convergen a las cantidades posteriores de interés.

Bosquejo de la idea ergódica

La intuición es la siguiente:

- si la cadena olvida gradualmente su estado inicial,
- y si pasa el tiempo correcto en cada región del espacio,
- entonces la frecuencia relativa con la que visita los conjuntos reproduce la distribución objetivo.

Por eso los promedios a lo largo de una trayectoria larga se comportan como integrales respecto a π .

Burn-in y autocorrelación

Dos aspectos prácticos importantes:

Burn-in

- las primeras iteraciones dependen mucho del valor inicial,
- por eso se suelen descartar.

Autocorrelación

- las muestras MCMC no son independientes,
- observaciones consecutivas suelen parecerse.

Entonces, aunque generemos muchas iteraciones, la información efectiva puede ser menor que el número total de muestras.

Ahora: Gibbs sampling

Gibbs sampling es otro método MCMC, pero con una estructura especial.
Supongamos que

$$\theta = (\theta_1, \theta_2, \dots, \theta_p).$$

Si conocemos las distribuciones condicionales completas:

$$p(\theta_1 \mid \theta_2, \dots, \theta_p, y), \quad p(\theta_2 \mid \theta_1, \theta_3, \dots, \theta_p, y), \quad \dots$$

entonces podemos muestrear una coordenada a la vez.

Algoritmo Gibbs

Dado el estado actual

$$\theta^{(t)} = (\theta_1^{(t)}, \dots, \theta_p^{(t)}),$$

hacemos:

$$\theta_1^{(t+1)} \sim p(\theta_1 \mid \theta_2^{(t)}, \dots, \theta_p^{(t)}, y),$$

$$\theta_2^{(t+1)} \sim p(\theta_2 \mid \theta_1^{(t+1)}, \theta_3^{(t)}, \dots, \theta_p^{(t)}, y),$$

$\vdots$

$$\theta_p^{(t+1)} \sim p(\theta_p \mid \theta_1^{(t+1)}, \dots, \theta_{p-1}^{(t+1)}, y).$$

Cada iteración actualiza los parámetros uno por uno.

La intuición detrás de Gibbs

La idea es más simple de lo que parece:

Si la distribución conjunta es difícil, quizá sus condicionales completas sean fáciles.

Entonces, en vez de intentar muestrear todo θ de una sola vez, muestreemos cada componente condicionado en los demás.

Repitiendo este ciclo, la cadena recorre la distribución conjunta.

Caso de dos variables

Supongamos

$$\theta = (\theta_1, \theta_2).$$

Entonces Gibbs alterna:

$$\theta_1^{(t+1)} \sim p(\theta_1 \mid \theta_2^{(t)}, y),$$

$$\theta_2^{(t+1)} \sim p(\theta_2 \mid \theta_1^{(t+1)}, y).$$

Geométricamente:

- primero nos movemos “horizontalmente” de acuerdo con una condicional,
- luego “verticalmente” de acuerdo con la otra.

Así la cadena explora la distribución conjunta.

¿Por qué Gibbs funciona?

La razón profunda es que cada actualización usa una distribución compatible con la conjunta objetivo.

Si actualizamos una coordenada usando la condicional correcta, entonces ese paso deja invariante a la distribución conjunta.

Componiendo todos esos pasos, obtenemos una cadena cuya distribución estacionaria es precisamente la distribución conjunta que queremos estudiar.

Bosquejo: un paso de Gibbs preserva la conjunta (1)

Consideremos dos variables (x, z) y un paso que actualiza sólo x :

$$K((x, z), (x', z')) = \pi(x' | z) \mathbf{1}\{z' = z\}.$$

Queremos ver que esto preserva $\pi(x, z)$.

Integramos respecto al estado de origen:

$$\int \pi(x, z) K((x, z), (x', z')) dx dz.$$

Sustituyendo el kernel:

$$\int \pi(x, z) \pi(x' | z) \mathbf{1}\{z' = z\} dx dz.$$

Bosquejo: un paso de Gibbs preserva la conjunta (2)

La indicadora fuerza $z = z'$, así que queda:

$$\int \pi(x, z') \pi(x' | z') dx.$$

Ahora usamos que

$$\pi(x, z') = \pi(z')\pi(x | z'),$$

entonces:

$$\pi(z')\pi(x' | z') \int \pi(x | z') dx = \pi(z')\pi(x' | z') = \pi(x', z').$$

Ese paso de Gibbs deja invariante a $\pi(x, z)$.

Conclusión del bosquejo para Gibbs

Si cada actualización individual preserva la distribución conjunta, entonces la composición de todas las actualizaciones también la preserva.

Por eso el barrido completo de Gibbs tiene a π como distribución estacionaria.

Después, bajo condiciones de ergodicidad, la cadena converge a esa distribución.

Gibbs como caso especial de Metropolis–Hastings

Gibbs puede verse como un caso especial de Metropolis–Hastings.

Supongamos que queremos actualizar θ_j y proponemos directamente desde su condicional completa:

$$q(\theta_j^* \mid \theta_{-j}) = p(\theta_j^* \mid \theta_{-j}, y).$$

Entonces, al escribir la razón de aceptación de Metropolis–Hastings, todos los términos se cancelan y resulta:

$$\alpha = 1.$$

Es decir, en Gibbs toda propuesta se acepta.

Bosquejo algebraico de que en Gibbs $\alpha = 1$

Partimos de

$$\alpha = \min \left(1, \frac{\pi(\theta_j^*, \theta_{-j}) q(\theta_j^{(t)} | \theta_j^*, \theta_{-j})}{\pi(\theta_j^{(t)}, \theta_{-j}) q(\theta_j^* | \theta_j^{(t)}, \theta_{-j})} \right).$$

En Gibbs,

$$q(\theta_j^* | \theta_j^{(t)}, \theta_{-j}) = p(\theta_j^* | \theta_{-j}),$$

y análogamente

$$q(\theta_j^{(t)} | \theta_j^*, \theta_{-j}) = p(\theta_j^{(t)} | \theta_{-j}).$$

Además,

$$\pi(\theta_j, \theta_{-j}) = p(\theta_j | \theta_{-j}) p(\theta_{-j}).$$

Sustituyendo todo:

$$\alpha = \min \left(1, \frac{p(\theta_j^* | \theta_{-j}) p(\theta_{-j}) p(\theta_j^{(t)} | \theta_{-j})}{p(\theta_j^{(t)} | \theta_{-j}) p(\theta_{-j}) p(\theta_j^* | \theta_{-j})} \right) = 1.$$

Metropolis–Hastings vs Gibbs

	Metropolis–Hastings	Gibbs
Generalidad	Muy general	Requiere condicionales completas
Aceptación	A veces rechaza	Siempre acepta
Diseño	Hay que elegir propuesta	Hay que derivar condicionales
Costo por iteración	Variable	A menudo bajo
Interpretación	Proponer/corregir	Actualizar por bloques o coordenadas

¿Cuándo usar cada uno?

Metropolis–Hastings es útil cuando:

- podemos evaluar la posterior hasta proporcionalidad,
- pero no sabemos muestrear fácilmente de las condicionales completas.

Gibbs es útil cuando:

- las condicionales completas tienen formas conocidas,
- actualizar por coordenadas o bloques es sencillo.

En muchos modelos reales se usan esquemas híbridos: algunos pasos de Gibbs y otros de Metropolis.

Lo esencial que debemos recordar

- ➊ MCMC no busca sólo un máximo: busca describir una distribución.
- ➋ Metropolis–Hastings construye una cadena mediante propuestas y aceptación/rechazo.
- ➌ La idea matemática central es el balance detallado.
- ➍ Gibbs usa condicionales completas y puede verse como un caso especial de MH.
- ➎ La teoría ergódica justifica que los promedios a lo largo de la cadena aproximan cantidades posteriores.

¿Qué esperar al correr una cadena?

Cuando implementamos MCMC, suelen aparecer tres objetos visuales muy importantes:

- 1 **Trace plots:** cómo evoluciona la cadena en el tiempo.
- 2 **Histogramas o densidades:** aproximación a la marginal posterior.
- 3 **Nubes de puntos:** dependencia entre parámetros.

CODE

Burn-in

Las primeras iteraciones de una cadena suelen depender mucho del valor inicial. Por eso normalmente se descartan las primeras observaciones de la cadena. A esto se le llama:

burn-in

La idea es quedarnos con la parte de la cadena que ya está explorando la distribución objetivo de manera más estable.

Convergencia

Una pregunta central en MCMC es:

Pregunta

¿La cadena ya está representando bien la posterior?

Esto se relaciona con la noción de **convergencia**.

En la práctica, la convergencia se estudia con:

- gráficas de trazas,
- comparación entre varias cadenas,
- diagnósticos específicos.

Más adelante veremos estos diagnósticos con detalle.

Autocorrelación

A diferencia de una muestra aleatoria simple, en MCMC las observaciones consecutivas no son independientes.

Esto produce **autocorrelación** en la cadena.

Consecuencia:

- muchas iteraciones pueden contener información parecida,
- el tamaño de muestra “efectivo” es menor que el número total de iteraciones.

Aun así, si la cadena está bien construida, sigue siendo útil para aproximar la posterior.

Cuando no podemos resolver la posterior,
todavía podemos **explorarla**.

Y esa es la idea central detrás de **MCMC**.