

Modelos Estadísticos

Maestría en Computo Estadístico

Dr. Marco Antonio Aquino López

Centro de Investigación en Matemáticas

2026



Motivación: la distribución muestral

Supongamos que tenemos datos

$$X_1, \dots, X_n \stackrel{iid}{\sim} F.$$

Queremos estimar una cantidad poblacional

$$\theta = T(F),$$

usando un estimador

$$\hat{\theta} = T(X_1, \dots, X_n).$$

La pregunta fundamental es:


¿Qué tan variable es $\hat{\theta}$?

Es decir, queremos conocer la distribución de

$$\hat{\theta} - \theta \quad \text{o} \quad \sqrt{n}(\hat{\theta} - \theta).$$

Distribución muestral ideal

Si conociéramos F , podríamos imaginar repetir el experimento muchas veces:



La distribución de

$$\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3, \dots$$

es la distribución muestral del estimador.

Problema

En la práctica no conocemos F , y solo tenemos una muestra observada.

La idea bootstrap

El bootstrap propone reemplazar

$$F$$

por una aproximación estimada

$$\hat{F}.$$

Entonces simulamos datos nuevos desde $\hat{F}$, no desde F .

$$F \rightsquigarrow \hat{F}$$

Dependiendo de cómo construimos $\hat{F}$, obtenemos distintos tipos de bootstrap:

- Bootstrap clásico: $\hat{F} = \hat{F}_n$, la distribución empírica.
- Bootstrap residual: $\hat{F}$ describe la distribución de los errores.
- Bootstrap paramétrico: $\hat{F} = F_{\hat{\theta}}$, un modelo paramétrico ajustado.

El paralelismo central del bootstrap

En el mundo real:

$$\hat{\theta} - \theta$$

es el error de estimación.

En el mundo bootstrap:

$$\hat{\theta}^* - \hat{\theta}$$

juega el papel del error de estimación.

La aproximación central es

$$\mathcal{L}_F\left(\sqrt{n}(\hat{\theta} - \theta)\right) \approx \mathcal{L}_{\hat{F}}\left(\sqrt{n}(\hat{\theta}^* - \hat{\theta}) \mid X_1, \dots, X_n\right).$$

Interpretación

El estimador original $\hat{\theta}$ juega, en el mundo bootstrap, el papel que θ juega en el mundo real.

Bootstrap clásico: distribución empírica

Supongamos que

$$X_1, \dots, X_n \stackrel{iid}{\sim} F.$$

El bootstrap clásico reemplaza F por la distribución empírica:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x).$$

Esta distribución pone masa $1/n$ en cada observación:

$$\mathbb{P}_{\hat{F}_n}(X^* = X_i) = \frac{1}{n}, \quad i = 1, \dots, n.$$

Consecuencia

Simular desde $\hat{F}_n$ equivale a muestrear con reemplazo de los datos observados.

Bootstrap clásico: algoritmo

Sea

$$\hat{\theta} = T(X_1, \dots, X_n).$$

Para $b = 1, \dots, B$:

- 1 Generar una muestra bootstrap:

$$X_1^{*(b)}, \dots, X_n^{*(b)} \sim \hat{F}_n.$$

- 2 Calcular el estimador bootstrap:


$$\hat{\theta}^{*(b)} = T(X_1^{*(b)}, \dots, X_n^{*(b)}).$$

Al final usamos

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$$

para aproximar la distribución de $\hat{\theta}$.

Mundo bootstrap



$\hat{\theta}^* - \hat{\theta}$ imita a $\hat{\theta} - \theta$.

Figura

Ver código 00

Justificación teórica: caso de la media

Consideremos

$$X_1, \dots, X_n \stackrel{iid}{\sim} F, \quad \mathbb{E}(X_i) = \mu, \quad \text{Var}(X_i) = \sigma^2 < \infty.$$

El estimador es

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Por el Teorema Central del Límite,

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N(0, \sigma^2).$$

La pregunta bootstrap es:

$$\sqrt{n}(\bar{X}^* - \bar{X}) \mid X_1, \dots, X_n \quad \text{¿tiene una distribución parecida?}$$

Media bootstrap: esperanza y varianza condicional

Condicionalmente en los datos,

$$X_1^*, \dots, X_n^* \sim \hat{F}_n.$$

Entonces

$$\mathbb{E}^*(X_i^*) = \bar{X},$$

y

$$\text{Var}^*(X_i^*) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Por lo tanto,

$$\mathbb{E}^*(\bar{X}^*) = \bar{X},$$

y

$$\text{Var}^*(\bar{X}^*) = \frac{1}{n} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right].$$

Bosquejo de consistencia para la media

La cantidad bootstrap relevante es

$$\sqrt{n}(\bar{X}^* - \bar{X}).$$

Condicionalmente en los datos, por un argumento tipo TCL,

$$\sqrt{n}(\bar{X}^* - \bar{X}) \approx N(0, s_n^2),$$

donde

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Por la Ley de los Grandes Números,

$$s_n^2 \xrightarrow{p} \sigma^2.$$

Por tanto,

$$\sqrt{n}(\bar{X}^* - \bar{X})$$

imita asintóticamente a

$$\sqrt{n}(\bar{X} - \mu).$$

Más allá de la media

Para un estimador general,

$$\theta = T(F), \quad \hat{\theta} = T(\hat{F}_n),$$

el bootstrap clásico usa

$$\hat{\theta}^* = T(\hat{F}_n^*).$$

La intuición es:

$$T(\hat{F}_n^*) - T(\hat{F}_n) \quad \text{imita a} \quad T(\hat{F}_n) - T(F).$$

Principio

El bootstrap funciona bien cuando el funcional T es suficientemente regular ante perturbaciones de F .

Advertencia

Puede fallar para funcionales no suaves, extremos o parámetros en la frontera.

Intervalos de confianza bootstrap

Después de obtener las muestras bootstrap,

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)},$$

podemos usar esta distribución para construir intervalos de confianza.

Error estándar bootstrap

Después de obtener

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)},$$

podemos estimar el error estándar de $\hat{\theta}$:

$$\widehat{\text{se}}_{\text{boot}}(\hat{\theta}) = \left[\frac{1}{B-1} \sum_{b=1}^B \left(\hat{\theta}^{*(b)} - \bar{\theta}^* \right)^2 \right]^{1/2},$$

donde

$$\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{*(b)}.$$

Interpretación

La dispersión de los estimadores bootstrap estima la dispersión del estimador original.

Intervalos de confianza bootstrap

Intervalo normal bootstrap:

$$\hat{\theta} \pm z_{0.975} \widehat{\text{se}}_{\text{boot}}(\hat{\theta}).$$

Intervalo percentil:

$$\left[q_{0.025}(\hat{\theta}^*), q_{0.975}(\hat{\theta}^*) \right].$$

Intervalo básico:

$$\left[2\hat{\theta} - q_{0.975}(\hat{\theta}^*), 2\hat{\theta} - q_{0.025}(\hat{\theta}^*) \right].$$

Discusión

Cada intervalo usa la distribución bootstrap de manera ligeramente distinta.

distribución bootstrap e intervalos

Ver código 02

Bootstrap residual: contexto

Consideremos el modelo lineal

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad i = 1, \dots, n.$$

En forma matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Suponemos

$$\mathbb{E}(\varepsilon_i) = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2.$$

El estimador de mínimos cuadrados es

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

La incertidumbre de $\hat{\boldsymbol{\beta}}$ proviene de los errores ε_i , pero no los observamos.

Residuos como aproximación de errores

Después de ajustar el modelo, obtenemos

$$\hat{Y}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}},$$

y los residuos

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i.$$

El bootstrap residual usa la distribución empírica de los residuos para aproximar la distribución de los errores:

$$G_\varepsilon \approx \hat{G}_{\hat{\varepsilon}}.$$

Usualmente usamos residuos centrados:

$$\tilde{\varepsilon}_i = \hat{\varepsilon}_i - \bar{\hat{\varepsilon}}.$$

Idea

Simular nuevos errores y pegarlos sobre la media ajustada del modelo.

Bootstrap residual: algoritmo

Primero ajustamos el modelo original y calculamos

$$\hat{Y}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}, \quad \tilde{\varepsilon}_i = \hat{\varepsilon}_i - \bar{\hat{\varepsilon}}.$$

Para $b = 1, \dots, B$:

- 1 Remuestrear residuos:

$$\varepsilon_1^{*(b)}, \dots, \varepsilon_n^{*(b)} \sim \hat{G}_{\tilde{\varepsilon}}.$$

- 2 Construir respuestas bootstrap:

$$Y_i^{*(b)} = \hat{Y}_i + \varepsilon_i^{*(b)}.$$

- 3 Reajustar el modelo:

$$\hat{\boldsymbol{\beta}}^{*(b)} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}^{*(b)}.$$

Figura bootstrap residual

Ver código 03

El mundo real:

$$Y_i = x_i^\top \beta + \varepsilon_i.$$

El mundo bootstrap:

$$Y_i^* = x_i^\top \hat{\beta} + \varepsilon_i^*.$$

Analogía

En el mundo bootstrap, $\hat{\beta}$ juega el papel de β .

Justificación teórica del bootstrap residual

En el modelo lineal,

$$\hat{\beta} - \beta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \epsilon.$$

En el mundo bootstrap,

$$\hat{\beta}^* - \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \epsilon^*.$$

La estructura es paralela:

error real del estimador = transformación lineal de errores reales,

error bootstrap = transformación lineal de errores bootstrap.

Si $\hat{G}_{\hat{\epsilon}} \approx G_{\epsilon}$, entonces esperamos que

$$\mathcal{L}^*(\hat{\beta}^* - \hat{\beta}) \approx \mathcal{L}(\hat{\beta} - \beta).$$

Bootstrap residual vs bootstrap de pares

En regresión también podríamos remuestrear pares:

$$(x_i, Y_i).$$

Esto genera muestras bootstrap:

$$(x_1^*, Y_1^*), \dots, (x_n^*, Y_n^*).$$

En cambio, el bootstrap residual mantiene fija la matriz de diseño:

X fija.

Método	Qué remuestrea	Cuándo es natural
Pares	(x_i, Y_i)	covariables aleatorias
Residual	$\hat{\varepsilon}_i$	diseño fijo

Cuándo puede fallar el bootstrap residual

El bootstrap residual simple supone que los errores son aproximadamente iid:

$$\varepsilon_i \stackrel{iid}{\sim} G.$$

Puede ser problemático si hay:

- heterocedasticidad,

$$\text{Var}(\varepsilon_i | x_i) \neq \sigma^2;$$

- dependencia entre observaciones;
- mala especificación del modelo;
- puntos altamente influyentes.

Intuición

Si la variabilidad del error cambia con x , remuestrear residuos globalmente rompe esa estructura.

Bootstrap paramétrico

Ahora asumimos una familia paramétrica:

$$X_i \sim f(x | \theta).$$

Estimamos el parámetro:

$$\hat{\theta}.$$

Después generamos datos desde el modelo ajustado:

$$X_1^*, \dots, X_n^* \sim f(x | \hat{\theta}).$$

Finalmente recalculamos

$$\hat{\theta}^*$$

en cada muestra bootstrap.

Idea

El modelo ajustado $f(x | \hat{\theta})$ reemplaza al mecanismo generador verdadero.

Bootstrap paramétrico: algoritmo

- 1 Ajustar el modelo paramétrico:

$$X_i \sim f(x | \theta).$$

- 2 Obtener:

$$\hat{\theta}.$$

- 3 Para $b = 1, \dots, B$, simular:

$$X_1^{*(b)}, \dots, X_n^{*(b)} \sim f(x | \hat{\theta}).$$

- 4 Recalcular:

$$\hat{\theta}^{*(b)}.$$

- 5 Usar:

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$$

para aproximar incertidumbre.

Justificación teórica: caso de máxima verosimilitud

Supongamos

$$X_1, \dots, X_n \sim f(x | \theta),$$

y que $\hat{\theta}$ es el estimador de máxima verosimilitud.

Bajo condiciones regulares,

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, I(\theta)^{-1}),$$

donde $I(\theta)$ es la información de Fisher.

En el bootstrap paramétrico:

$$X_1^*, \dots, X_n^* \sim f(x | \hat{\theta}).$$

Entonces, condicionalmente en los datos,

$$\sqrt{n}(\hat{\theta}^* - \hat{\theta}) \approx N(0, I(\hat{\theta})^{-1}).$$

Consistencia del bootstrap paramétrico

Si

$$\hat{\theta} \xrightarrow{P} \theta,$$

entonces

$$I(\hat{\theta})^{-1} \xrightarrow{P} I(\theta)^{-1}.$$

Por lo tanto,

$$\mathcal{L}^* \left[\sqrt{n}(\hat{\theta}^* - \hat{\theta}) \right] \approx \mathcal{L} \left[\sqrt{n}(\hat{\theta} - \theta) \right].$$

Conclusión

El bootstrap paramétrico hereda su validez de la correcta especificación del modelo y de la regularidad del estimador.

Ejemplo: bootstrap paramétrico Poisson

Supongamos

$$X_i \sim \text{Poisson}(\lambda).$$

El estimador de máxima verosimilitud es

$$\hat{\lambda} = \bar{X}.$$

El bootstrap paramétrico simula

$$X_i^* \sim \text{Poisson}(\hat{\lambda}).$$


Después calcula

$$\hat{\lambda}^* = \bar{X}^*.$$

La distribución de

$$\hat{\lambda}^* - \hat{\lambda}$$

Bosquejo de bootstrap paramétrico



Animación

Ver código 04

Comparación de los tres bootstrap

Método	Distribución adora	gener-	Qué reemplaza	Supuesto clave
Clásico	$\hat{F}_n$		F por distribución em- pírica	Datos iid
Residual	$\hat{G}_{\hat{\varepsilon}}$		Distribución de errores	Errores iid, modelo correcto
Paramétrico	$f(\cdot \mid \hat{\theta})$		Parámetro verdadero por estimado	Modelo correcto

Mensaje

Los tres métodos siguen la misma lógica, pero usan diferentes mecanismos generadores.

Qué aproxima cada método

Método	Mundo real	Mundo bootstrap
Clásico	$\hat{\theta} - \theta$	$\hat{\theta}^* - \hat{\theta}$
Residual	$\hat{\beta} - \beta$	$\hat{\beta}^* - \hat{\beta}$
Paramétrico	$\hat{\theta} - \theta$	$\hat{\theta}^* - \hat{\theta}$

Principio común

La variabilidad del estimador en el mundo bootstrap imita la variabilidad del estimador en el mundo real.

$$\mathcal{L}^*(\text{error bootstrap}) \approx \mathcal{L}(\text{error real}).$$

Cuándo puede fallar el bootstrap

El bootstrap puede ser delicado cuando:

- el tamaño de muestra es pequeño;
- el estimador no es suave;
- hay dependencia no modelada;
- hay observaciones extremas muy influyentes;
- el parámetro está en la frontera;
- el modelo paramétrico está mal especificado;
- se usa bootstrap residual con heterocedasticidad fuerte.

Mensaje crítico

El bootstrap no elimina los supuestos. Lo mueve al mecanismo usado para generar datos nuevos.

Ejemplo de falla: el máximo muestral

Sea

$$\theta = \max \text{supp}(F),$$

y supongamos que estimamos con

$$\hat{\theta} = \max(X_1, \dots, X_n).$$

El bootstrap clásico remuestrea desde los datos observados.

Entonces siempre se cumple

$$\max(X_1^*, \dots, X_n^*) \leq \max(X_1, \dots, X_n).$$

Problema

La distribución empírica no puede generar valores más grandes que el máximo observado.

Por eso el bootstrap clásico puede subestimar la incertidumbre de estimadores extremos.

Resumen

- El bootstrap busca aproximar la distribución muestral de un estimador.
- La idea central es:

$$\hat{\theta}^* - \hat{\theta} \text{ imita a } \hat{\theta} - \theta.$$

- En el bootstrap clásico:

$$F \approx \hat{F}_n.$$

- En el bootstrap residual:

$$G_\epsilon \approx \hat{G}_{\hat{\epsilon}}.$$

- En el bootstrap paramétrico:

$$F \approx F_{\hat{\theta}}.$$

Frase final

El bootstrap convierte un problema analítico difícil en un problema computacional, pero su validez depende de que el mundo bootstrap imite adecuadamente al mundo real.